

CE043 - GAMLSS

Silva, J.P; Taconeli, C.A.


29 de agosto de 2020

Exemplo usando `gamlssNP()`: dados de cérebros de animais

O tamanho do cérebro (`brain`) e o peso corporal (`body`) foram registrados para 28 espécies de animais terrestres. Como a distribuição do tamanho do cérebro e do peso corporal são ambas altamente assimétricas, uma transformação logarítmica foi aplicada às variáveis. Assim, trabalharemos com as variáveis transformadas `lbrain` e `lbody`.

A seguir, gráfico dos dados resultantes.

```
library(gamlss.mx)
data(brains)
brains <- transform(brains, lbrain = log(brain), lbody = log(body))
par(mfrow=c(1,2))
with(brains, plot(brain~body, ylab="brain", xlab="body"))
with(brains, plot(lbrain~lbody, ylab="log brain", xlab="log body"))
```



Um modelo de regressão linear com erros normais para `lbrain` versus `lbody` tem uma inclinação altamente significativa para `lbody` mas se acredita que os dados possam representar diferentes estágios evolutivos e, portanto, um modelo de mistura será ajustado aos dados.

```
summary(lm(lbrain ~ lbody, data = brains))
```

```
##
## Call:
## lm(formula = lbrain ~ lbody, data = brains)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.2890 -0.6763  0.3316  0.8646  2.5835
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.55490     0.41314   6.184 1.53e-06 ***
## lbody         0.49599     0.07817   6.345 1.02e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.532 on 26 degrees of freedom
## Multiple R-squared:  0.6076, Adjusted R-squared:  0.5925
## F-statistic: 40.26 on 1 and 26 DF,  p-value: 1.017e-06
```

No modelo de mistura, a estágio evolutivo é representado por uma alteração no intercepto da equação do modelo. Modelos de mistura normal com 1, 2, 3 e 4 componentes são ajustados abaixo. Os modelos `br.2`, `br.3` e `br.4` são modelos com diferentes interceptos para os K componentes, i.e. $f_{\kappa}(y)$ é $NO(\mu_{\kappa}, \sigma)$, em que, para $\kappa = 1, 2, 3, 4$, temos:

$$\mu_{\kappa} = \beta_{0\kappa} + \beta_1 x, \kappa = 1, \dots, K,$$

y é o logaritmo do tamanho do cérebro, e x é o logaritmo do peso corporal.

Já que as inclinações são as mesmas para os K componentes, são ajustadas retas paralelas. Aqui omitimos os gráficos das trajetórias do algoritmo EM na função `gamlssNP()`.

```
br.1 <- gamlss(lbrain ~ lbody, data = brains, trace=FALSE) #mesmo que o anterior
br.2 <- gamlssNP(formula=lbrain~lbody, mixture="np", K=2, tol=1, data=brains, family=NO,
  plot.opt=0)
```

```
## 1 ..2 ..3 ..4 ..5 ..6 ..7 ..8 ..9 ..10 ..11 ..12 ..13 ..14 ..15 ..16 ..
## 17 ..18 ..19 ..20 ..21 ..22 ..23 ..24 ..25 ..26 ..27 ..28 ..29 ..30 ..31 ..32 ..33 ..
##
## EM algorithm met convergence criteria at iteration 33
```

```
br.3 <- gamlssNP(formula=lbrain~lbody, mixture="np", K=3, tol=1, data=brains, family=NO,
  plot.opt=0)
```

```
## 1 ..2 ..3 ..4 ..5 ..6 ..7 ..8 ..9 ..10 ..11 ..12 ..13 ..14 ..
## EM algorithm met convergence criteria at iteration 14
```

```
br.4 <- gamlssNP(formula=lbrain~lbody, mixture="np", K=4, tol=1, data=brains, family=NO,
  plot.opt=0)
```

```
## 1 ..2 ..3 ..4 ..5 ..6 ..7 ..8 ..9 ..10 ..11 ..12 ..13 ..14 ..15 ..16 ..
## 17 ..18 ..19 ..20 ..21 ..22 ..23 ..24 ..25 ..26 ..27 ..28 ..29 ..
## EM algorithm met convergence criteria at iteration 29
```

Comparamos os modelos pelos critérios AIC e BIC:

```
GAIC(br.1, br.2, br.3, br.4)
```

```
##      df      AIC
## br.3  7  79.15079
## br.4  9  83.15613
## br.2  5  85.95938
## br.1  3 107.25779
```

```
GAIC(br.1, br.2, br.3, br.4, k = log(length(brains$body)))
```

```
##      df      AIC
## br.3  7  88.47622
## br.2  5  92.62040
## br.4  9  95.14598
## br.1  3 111.25440
```

O modelo `br.3` com três componentes (i.e. três retas paralelas) é selecionado por ambos os critérios. A alteração dos valores iniciais testando diferentes valores para `tol` (e.g. testando cada um dos valores 0.1, 0.2, ..., 1 um por vez), nos modelos `br.2`, `br.3` e `br.4`, não alterou os valores do AIC e BIC mostrados acima.

O modelo `br.3` e suas probabilidades estimadas $\hat{p}_{i\kappa}$ são dadas a seguir.

```
br.3
```

```
##
## Mixing Family:  c("NO Mixture with NP", "Normal Mixture with NP")
##
## Fitting method: EM algorithm
##
## Call:  gamlssNP(formula = lbrain ~ lbody, family = NO, data = brains,
##      K = 3, mixture = "np", tol = 1, plot.opt = 0)
##
## Mu Coefficients :
## (Intercept)      lbody      MASS2      MASS3
##    -3.0715      0.7499      4.9805      6.5530
## Sigma Coefficients :
## (Intercept)
##    -0.9387
##
## Estimated probabilities: 0.1071429 0.7514161 0.141441
##
## Degrees of Freedom for the fit: 7 Residual Deg. of Freedom    21
## Global Deviance:      65.1508
##      AIC:      79.1508
##      SBC:      88.4762
```

O modelo `br.3` pode ser representado como $Y \sim NO(\hat{\mu}, \hat{\sigma})$, em que

$$\hat{\mu} = \begin{cases} -3.072 + 0.750x, & \text{com probabilidade 0.107} \\ 1.909 + 0.750x, & \text{com probabilidade 0.751} \\ 3.482 + 0.750x, & \text{com probabilidade 0.141} \end{cases}$$

e $\hat{\sigma} = \exp(-0.9387) = 0.391$. (Note que o intercepto para o segundo componente é obtido dos coeficientes estimados de μ fazendo $1.909 = -3.072 + 4.981$, já que MASS2 dá o ajustamento para o intercepto para o segundo componente de mistura; similarmente para MASS3.)

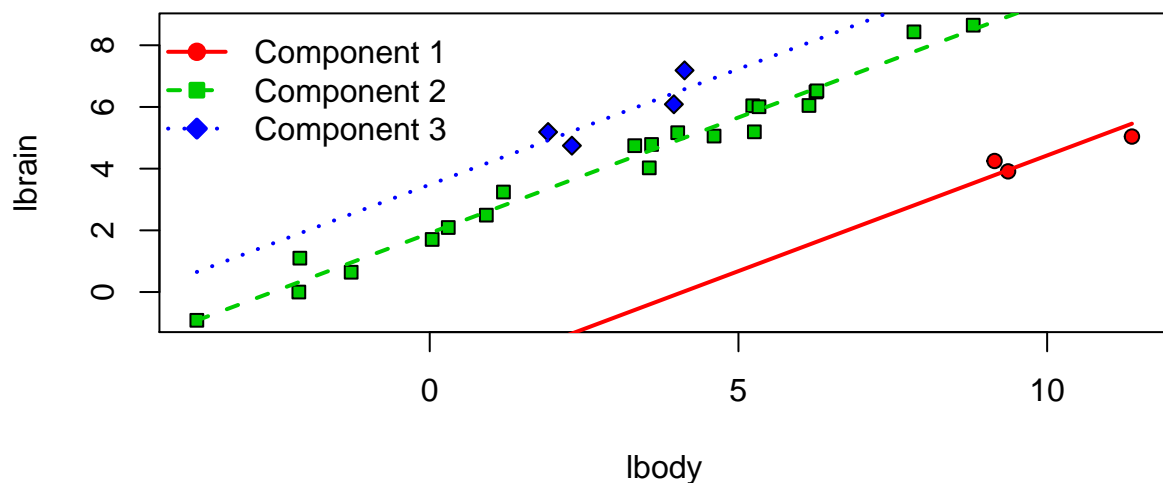
A saída dada por `br.3$post.prob` contém as probabilidades a posteriori estimadas $\hat{p}_{i\kappa}$ de cada observação pertencer a cada um dos três componentes dado que nós observamos a variável resposta `lbrain`.

```
head(br.3$post.prob[[1]])
```

```
##      [,1]      [,2]      [,3]
## [1,] 0 0.9999624 3.760045e-05
## [2,] 0 0.9999995 4.736429e-07
## [3,] 0 0.9996309 3.691210e-04
## [4,] 0 0.9979683 2.031733e-03
## [5,] 0 0.9999947 5.254125e-06
## [6,] 1 0.0000000 0.000000e+00
```

Um gráfico dos dados juntamente com os valores ajustados para o parâmetro μ no modelo `br.3` é mostrado na sequência. Cada observação foi alocada ao componente no qual tinha a maior probabilidade e as observações são mostradas usando diferentes símbolos para representar a alocação a cada um dos três componentes.

```
with(brains, plot(lbody, lbrain, pch = c(21, 22, 23)[max.col(br.3$post.prob[[1]])],
  bg = c("red", "green3", "blue")[max.col(br.3$post.prob[[1]])]))
for (k in 1:3){
  with(brains, lines(fitted(br.3, K=k)[order(lbody)]~lbody[order(lbody)], lty = k, lwd=2,
    col=c("red", "green3", "blue")[k]))}
legend("topleft", legend=c("Component 1", "Component 2", "Component 3"), pch=c(21, 22, 23),
  pt.bg=c("red", "green3", "blue"), lty=1:3, lwd=2, col=c("red", "green3", "blue"), bty="n")
```



Como o parâmetro μ neste caso é a média da distribuição, as linhas são as médias ajustadas das distribuições condicionais $f_{\kappa}(y)$ para $\kappa = 1, 2, 3$.

A média ponderada para o parâmetro (condicional) $\hat{\mu}$ para os K componentes para cada observação, i.e. $\sum_{\kappa=1}^K \hat{\pi}_{\kappa} \hat{\mu}_{i\kappa}$, é obtida fazendo:

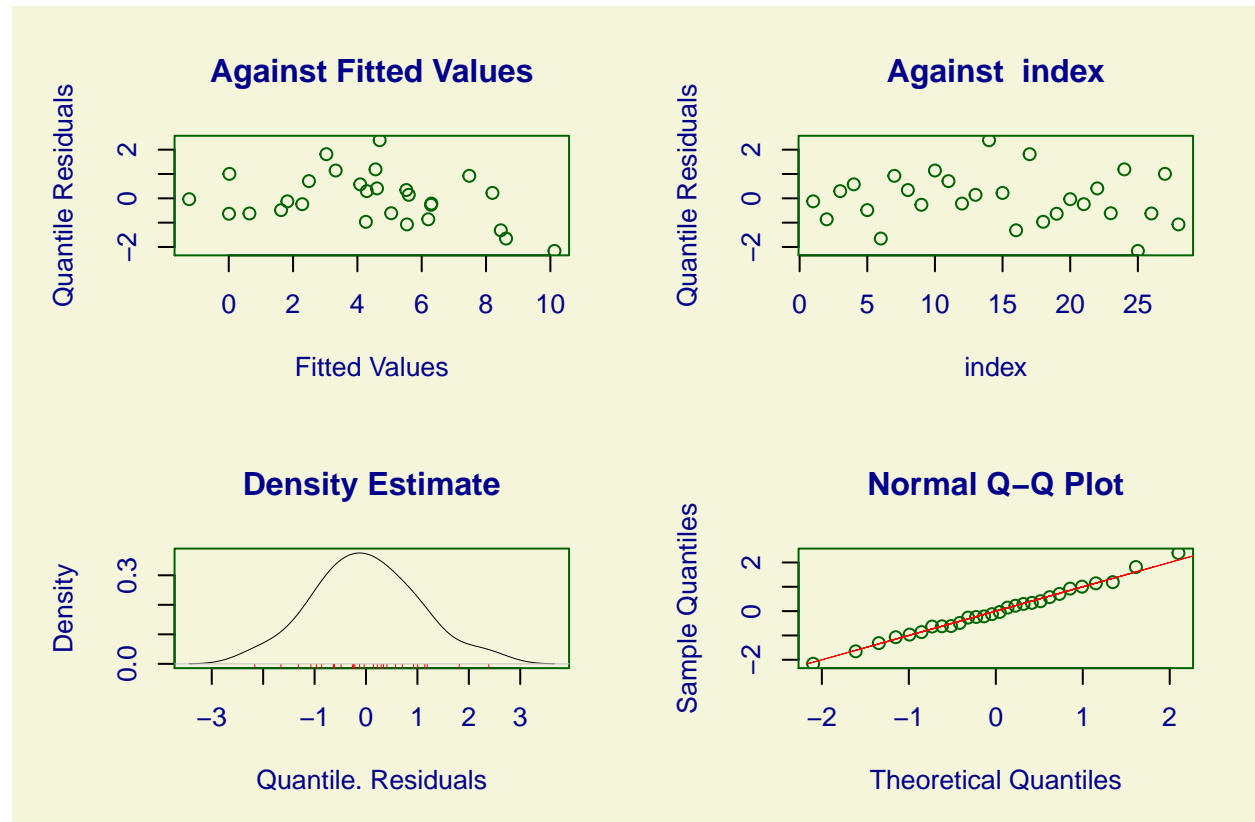
```
fitted(br.3, K=0)
```

```
## [1] 1.822865681 6.203952847 4.292065847 4.087590373 1.627218958
## [6] 8.622732780 7.479322889 5.521213700 6.289230269 3.324601819
## [11] 2.493173634 6.300658116 5.597014099 4.692900590 8.199489796
## [16] 8.458586995 3.035378886 4.264096322 0.007739749 -1.231155903
## [21] 2.284967057 4.609843938 5.051397782 4.563297461 10.127347762
## [26] 0.643160576 0.020135700 5.540601200
```

Note como a média marginal, usando a função `fitted()`, se compara com as médias condicionais. Se o argumento K da função `fitted()` recebe um valor entre 1, 2 ou 3 (que são os valores possíveis para o modelo `br.3`), então a quantidade condicional μ_1 , μ_2 ou μ_3 é dada. Para valor $K = 0$ a média μ é dada. Teremos a média marginal apenas se o parâmetro μ é a média da distribuição condicional de cada componente.

Um gráfico de resíduos do modelo de mistura é obtido da forma usual por meio da função `plot()`:

```
plot(br.3)
```



```
## *****
## Summary of the Randomised Quantile Residuals
##               mean    = -0.004003875
##               variance = 1.052469
```

```
##             coef. of skewness = 0.1668313
##             coef. of kurtosis  = 2.739025
## Filliben correlation coefficient = 0.9962244
## *****
```

Há vários modelos alternativos que nós poderíamos ajustar a esses dados, dependendo de quais parâmetros são comuns aos três componentes do modelo.

A tabela a seguir mostra possíveis modelos alternativos, que são ajustados na sequência.

modelo	μ intercepto	μ inclinação	σ
br.3	diferente	igual	igual
br.31	diferente	igual	diferente
br.32	diferente	diferente	igual
br.33	diferente	diferente	diferente

Note, contudo, que temos apenas 27 observações e, portanto, qualquer modelo de mistura deve ser tratado com grande cuidado!

```
br.31 <- gamlssNP(formula = lbrain ~ lbody, sigma.fo = ~MASS, mixture = "np", K = 3,
                  tol = 1, data = brains, family = NO, plot.opt=0)
```

```
## 1 ..2 ..3 ..4 ..5 ..6 ..7 ..8 ..9 ..10 ..11 ..12 ..13 ..14 ..15 ..16 ..
## 17 ..18 ..19 ..20 ..21 ..22 ..23 ..24 ..25 ..26 ..27 ..28 ..
## EM algorithm met convergence criteria at iteration 28
```

```
br.32 <- gamlssNP(formula = lbrain ~ lbody, random = ~lbody, sigma.fo = ~1, mixture = "np",
                  K = 3, tol = 1, data = brains, family = NO, plot.opt=0)
```

```
## 1 ..2 ..3 ..4 ..5 ..6 ..7 ..8 ..9 ..10 ..11 ..12 ..13 ..14 ..15 ..16 ..
##
## EM algorithm met convergence criteria at iteration 16
```

```
br.33 <- gamlssNP(formula = lbrain ~ lbody, random = ~lbody, sigma.fo = ~MASS, mixture = "np",
                  K = 3, tol = 1, data = brains, family = NO, plot.opt=0)
```

```
## 1 ..2 ..3 ..4 ..5 ..6 ..7 ..8 ..9 ..10 ..11 ..12 ..13 ..14 ..15 ..16 ..
## 17 ..
## EM algorithm met convergence criteria at iteration 17
```

Então comparamos os modelos via AIC e BIC:

```
GAIC(br.3, br.31, br.32, br.33)
```

```
##      df      AIC
## br.32  9 77.31133
## br.3   7 79.15079
## br.33 11 80.26824
## br.31  9 81.93037
```

```
GAIC(br.3, br.31, br.32, br.33, k = log(length(brains$tbody)))
```

```
##      df      AIC
## br.3   7 88.47622
## br.32  9 89.30117
## br.31  9 93.92021
## br.33 11 94.92249
```

Considerações:

- O modelo **br.3** tem o menor valor de BIC. Note que o modelo **br.32** tem o menor valor de AIC, mas com tantos parâmetros e tão poucos dados o modelo pode produzir resultados que não fazem sentido.
- Note também que, em geral, já que o modelo **br.33** tem componentes sem parâmetros em comum, este modelo poderia ser ajustado usando a função `gamlssMX()`.
- Novamente, com apenas 27 observações qualquer modelo ajustado é muito sensível aos valores iniciais.

Exemplo usando `gamlssMX()`: dados de óculos de leitura

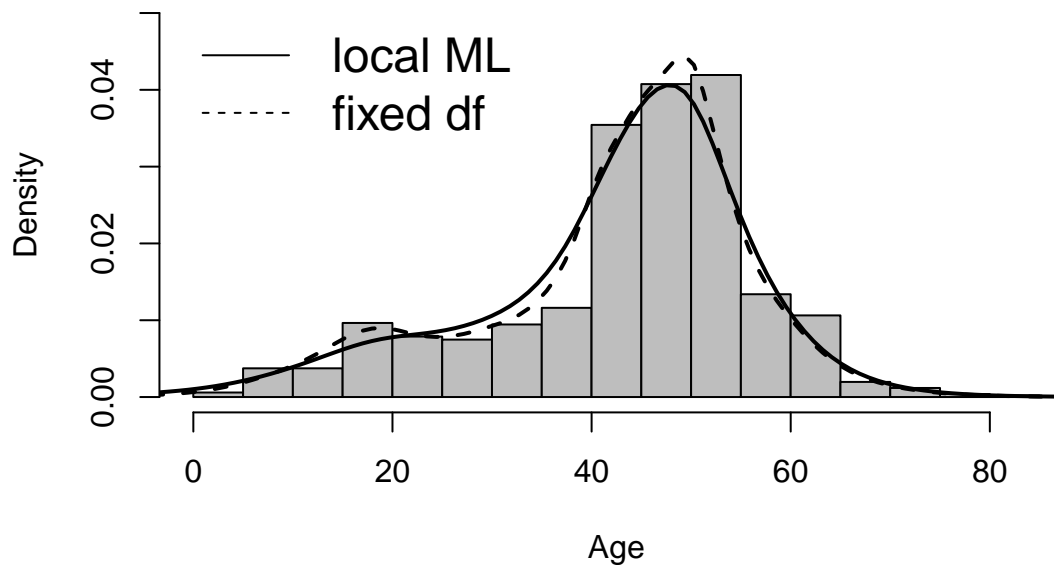
Os dados se referem à idade na qual os participantes ($n = 1016$) do estudo Blue Mountains Eye Study [Attebo et al., 1996] relataram que começaram a usar óculos de leitura (`ageread`). A única covariável é o sexo do indivíduo (`sex`).

```
library(gamlss)
data(glasses)
```

Primeiro, veremos como ajustar um modelo de mistura finita para `ageread` sem covariáveis, depois modelaremos `ageread` usando `sex` como variável explicativa.

A figura a seguir sugere que há duas subpopulações de indivíduos: aqueles que começaram a usar óculos na infância e início da idade adulta, e aqueles que começaram o uso mais tarde na vida. (As densidades foram criadas usando as funções `histSmo()` e `histSmoC()`.)

```
truehist(glasses$ageread, nbins=25, col="grey", xlab="Age",
ylab="Density", ylim=c(0,0.05))
lines(histSmo(glasses$ageread), lty=1, lwd=2)
lines(histSmoC(glasses$ageread, df=7), lty=2, lwd=2)
legend("topleft", legend=c("local ML", "fixed df"), lty=1:2, cex=1.5, bty="n")
```



Modelo sem covariável

Vamos ajustar vários modelos de mistura de dois componentes para distribuições contínuas e então selecionar o ‘melhor’ ajuste usando o AIC. Misturas das distribuições *normal*, *gamma*, *inversa gaussiana*, *Weibull*, *Gumbel reversa* e *logística* são ajustadas usando a função `gamlssMX()`, e então comparadas via `AIC()`:


```
library(gamlss.mx)
set.seed(3683)
readNO <- gamlssMX(ageread~1, family=NO, K=2, data=glasses, plot=FALSE)
readGA <- gamlssMX(ageread~1, family=GA, K=2, data=glasses, plot=FALSE)
readIG <- gamlssMX(ageread~1, family=IG, K=2, data=glasses, plot=FALSE)
readWEI <- gamlssMX(ageread~1, family=WEI, K=2, data=glasses, plot=FALSE)
readRG <- gamlssMX(ageread~1, family=RG, K=2, data=glasses, plot=FALSE)
readLO <- gamlssMX(ageread~1, family=LO, K=2, data=glasses, plot=FALSE)
AIC(readNO,readGA,readIG,readWEI,readRG,readLO)
```

```
##          df          AIC
## readLO    5 7930.470
## readGA    5 7930.677
## readRG    5 7949.452
## readWEI   5 7956.933
## readNO    5 7958.670
## readIG    5 7971.757
```

O melhor modelo é o logístico (LO), embora a gama (GA) retorne um ajuste comparável e possa ser preferido (porque assume uma resposta positiva). Vamos verificar que chegamos no máximo global usando a função `gamlssMXfits()` e ajustando cinco modelos com diferentes valores iniciais:

```
readLO1<-gamlssMXfits(n=5, ageread~1,family=LO,K=2,data=glasses)
```

Compare os resultados de `readLO1` e `readLO`:

```
readLO

##
## Mixing Family:  c("LO", "LO")
##
## Fitting method: EM algorithm
##
## Call:  gamlssMX(formula = ageread ~ 1, family = LO, K = 2, data = glasses,
##      plot = FALSE)
##
## Mu Coefficients for model: 1
## (Intercept)
##      18.86
## Sigma Coefficients for model: 1
## (Intercept)
##      1.492
## Mu Coefficients for model: 2
## (Intercept)
##      47.04
## Sigma Coefficients for model: 2
## (Intercept)
##      1.553
##
## Estimated probabilities: 0.1663841 0.8336159
##
## Degrees of Freedom for the fit: 5 Residual Deg. of Freedom    1011
```

```
## Global Deviance:      7920.47
##           AIC:        7930.47
##           SBC:        7955.09
```

```
readL01
```

```
##
## Mixing Family:  c("L0", "L0")
##
## Fitting method: EM algorithm
##
## Call:  gamlssMX(formula = ageread ~ 1, family = L0, K = 2, data = glasses)
##
## Mu Coefficients for model: 1
## (Intercept)
##      47.04
## Sigma Coefficients for model: 1
## (Intercept)
##      1.553
## Mu Coefficients for model: 2
## (Intercept)
##      18.85
## Sigma Coefficients for model: 2
## (Intercept)
##      1.491
##
## Estimated probabilities: 0.8336322 0.1663678
##
## Degrees of Freedom for the fit: 5 Residual Deg. of Freedom    1011
## Global Deviance:      7920.47
##           AIC:        7930.47
##           SBC:        7955.09
```


A distribuição logística tem função de ligação padrão identidade para μ e log para σ . O modelo estimado é dado por

$$f(y) = \hat{\pi}_1 f_1(y) + \hat{\pi}_2 f_2(y) \\ = 0.17 f_1(y) + 0.83 f_2(y)$$

em que $f_1(y)$ é a densidade da distribuição logística, $LO(\mu_1, \sigma_1)$ com $\hat{\mu}_1 = 18.86$ e $\hat{\sigma}_1 = \exp(1.492) = 4.45$ e $f_2(y)$ é a densidade da distribuição logística, $LO(\mu_2, \sigma_2)$ com $\hat{\mu}_2 = 47.04$ e $\hat{\sigma}_2 = \exp(1.553) = 4.73$.

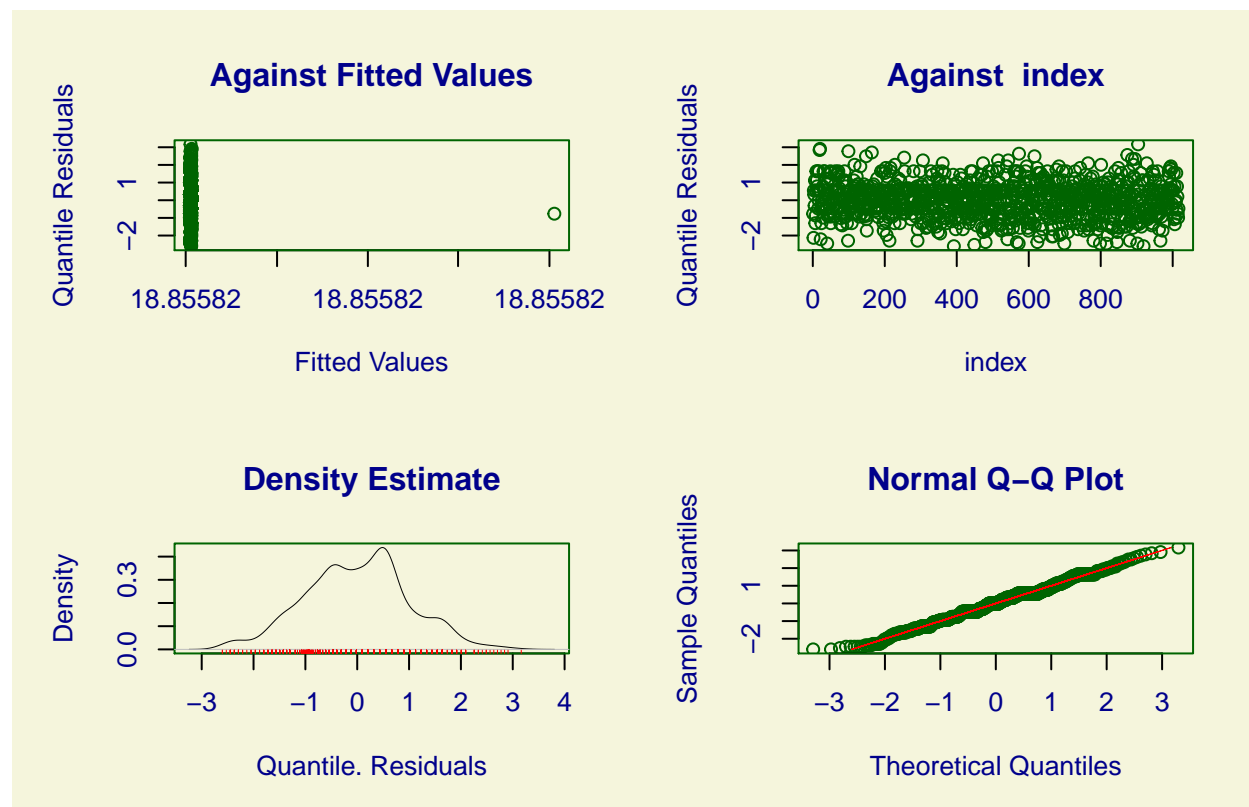
A seguir é mostrado o histograma dos dados juntamente com o modelo L0 de dois componentes ajustado.

```
### create a function to plot the fitted values of observation 1, i.e. case 1
fnL0 <- getpdfMX(readL0, observation=1)
fnGA <- getpdfMX(readGA, observation=1)
truehist(glasses$ageread, nbins=25, col="grey", xlab="Age",
ylab="Density", ymax=0.05)
lines(seq(0.5,90.5,1),fnL0(seq(0.5,90.5,1)), lty=1, lwd=2)
lines(seq(0.5,90.5,1),fnGA(seq(0.5,90.5,1)), lty=2, lwd=2, col=2)
legend("topleft",legend=c("logistic","gamma"),lty=1:2, cex=1.5, col=1:2, bty="n")
```



O comando `getpdfMX(readL0, observation=1)` cria uma nova função que pode ser usada para plotar a distribuição ajustada para uma observação específica. A seguir são apresentados os gráficos de resíduos.

```
plot(readL0)
```



```
## *****
## Summary of the Randomised Quantile Residuals
##               mean      = -0.0001824348
##               variance   = 0.9920201
##               coef. of skewness = 0.02470025
##               coef. of kurtosis = 2.922055
## Filliben correlation coefficient = 0.9968217
## *****
```

Note que o primeiro gráfico deve ser ignorado. Este é um gráfico dos resíduos versus valores preditos para μ , um gráfico útil para modelos de regressão com variáveis explicativas contínuas. Aqui, o modelo especifica uma constante para μ , assim todos os valores preditos são iguais e devem estar numa linha vertical no gráfico. O fato de que um deles parece não estar nesta linha se deve a uma pequena discrepância numérica (veja a escala horizontal). Isso aparece frequentemente em casos em que não há variáveis explicativas envolvidas no ajuste, e deve ser ignorado.

Como exercício, verifique se o número K de componentes deve ser aumentado.

Modelo com variável

Consideramos agora a inclusão da variável `sex` no modelo. Vamos comparar modelos que incluem `sex` no modelo para μ , no modelo para π , e em ambos:

```
readL01 <- gamlssMX(ageread~sex,family=L0,K=2,data=glasses, plot=FALSE)
readL02 <- gamlssMX(ageread~sex,pi.formula=~sex,family=L0,K=2, data=glasses, plot=FALSE)
readL03 <- gamlssMX(ageread~1,pi.formula=~sex,family=L0,K=2, data=glasses, plot=FALSE)
AIC(readL0,readL01,readL02,readL03)
```

```
##           df      AIC
## readL02   8 7916.746
## readL03   6 7918.782
## readL01   7 7924.246
## readL0    5 7930.470
```

O modelo preferido é `readL02`, que tem `sex` como covariável para μ e π :

```
readL02

##
## Mixing Family:  c("L0", "L0")
##
## Fitting method: EM algorithm
##
## Call:  gamlssMX(formula = ageread ~ sex, pi.formula = ~sex, family = L0,
##               K = 2, data = glasses, plot = FALSE)
##
## Mu Coefficients for model: 1
## (Intercept)              sex2
##    18.8519             0.2559
## Sigma Coefficients for model: 1
## (Intercept)
##    1.497
```

```

## Mu Coefficients for model: 2
## (Intercept)      sex2
##      46.417      1.483
## Sigma Coefficients for model: 2
## (Intercept)
##      1.546
## model for pi:
##      (Intercept)      sex2
## fac.fit2      1.368604 0.6525015
##
## Estimated probabilities:
##      pi1      pi2
## 1 0.1170047 0.8829953
## 2 0.2028455 0.7971545
## 3 0.2028455 0.7971545
## ...
##
## Degrees of Freedom for the fit: 8 Residual Deg. of Freedom    1008
## Global Deviance:      7900.75
##      AIC:      7916.75
##      SBC:      7956.14

```

As estimativas de μ_κ , σ_κ e π_κ para os componentes $\kappa = 1, 2$ são obtidas como:

- Componente 1:

$$\begin{aligned}
\hat{\mu}_1 &= 18.8519 + 0.2559I(\text{sex} = 2) \\
&= \begin{cases} 18.8519, & \text{para homens} \\ 19.1078, & \text{para mulheres} \end{cases} \\
\hat{\sigma}_1 &= \exp(1.497) = 4.468 \\
\hat{\pi}_1 &= 1 - \hat{\pi}_2 \\
&= \begin{cases} 1 - 0.7972 = 0.2028, & \text{para homens} \\ 1 - 0.8830 = 0.1170, & \text{para mulheres} \end{cases}
\end{aligned}$$

em que $\hat{\pi}_2$ é obtido do componente 2 abaixo

- Componente 2:

$$\begin{aligned}
\hat{\mu}_2 &= 46.417 + 1.483I(\text{sex} = 2) \\
&= \begin{cases} 46.4170, & \text{para homens} \\ 47.90, & \text{para mulheres} \end{cases} \\
\hat{\sigma}_2 &= \exp(1.546) = 4.6930 \\
\log\left(\frac{\hat{\pi}_2}{1 - \hat{\pi}_2}\right) &= 1.3686 + 0.6525I(\text{sex} = 2) \\
&= \begin{cases} 1.3686, & \text{para homens} \\ 2.0211, & \text{para mulheres} \end{cases} \\
\hat{\pi}_2 &= \begin{cases} \frac{1}{1 + \exp(-1.3686)} = 0.7972, & \text{para homens} \\ \frac{1}{1 + \exp(-2.0211)} = 0.8830, & \text{para mulheres} \end{cases}
\end{aligned}$$

Em resumo, temos a distribuição ajustada para a idade na qual se iniciou a usar óculos de leitura:


Homens: $f(y) = 0.20f_L(y|\hat{\mu}_1 = 18.85, \hat{\sigma}_1 = 4.47) + 0.80f_L(y|\hat{\mu}_2 = 46.42, \hat{\sigma}_2 = 4.69)$

Mulheres: $f(y) = 0.12f_L(y|\hat{\mu}_1 = 19.11, \hat{\sigma}_1 = 4.47) + 0.88f_L(y|\hat{\mu}_2 = 47.90, \hat{\sigma}_2 = 4.69)$

em que $f_L(\cdot|\mu, \sigma)$ corresponde à distribuição logística (L0). Entre os usuários de óculos, os homens têm maior probabilidade de começar a usar óculos na infância ou início da vida adulta.

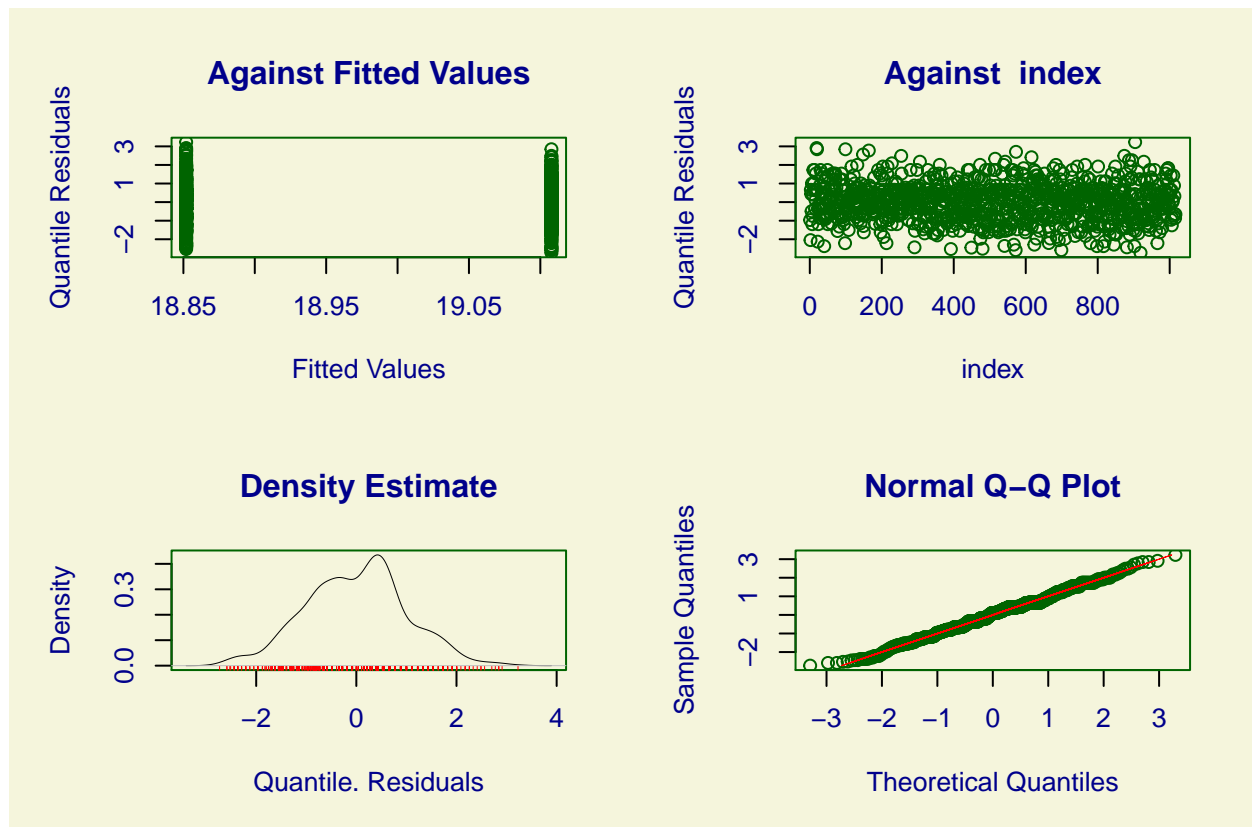
As densidades preditas são mostradas a seguir.

```
par(mfrow=c(1,2))
fnloFemale<-getpdfMX(readL02, observation=1)#observation 1 is female
fnloMale<-getpdfMX(readL02, observation=2)#observation 2 is male
truehist(glasses$ageread[glasses$sex==1],nbins=25,col="grey",
xlab="Age",ylab="Density",ymax=0.05, main="Males")
abline(h=(1:5)/100,lty=2,col="gray")
lines(seq(0.5,90.5,1),fnloMale(seq(0.5,90.5,1)), lwd=2)
truehist(glasses$ageread[glasses$sex==2],nbins=25,col="grey",
xlab="Age",ylab="Density",ymax=0.05, main="Females")
abline(h=(1:5)/100,lty=2,col="gray")
lines(seq(0.5,90.5,1),fnloFemale(seq(0.5,90.5,1)), lwd=2)
```



Por fim, diagnóstico do modelo:

```
plot(readL02)
```



```
## *****
##   Summary of the Randomised Quantile Residuals
##               mean    = -0.0006140894
##               variance = 0.9924708
##               coef. of skewness = 0.02460349
##               coef. of kurtosis = 2.936574
## Filliben correlation coefficient = 0.9978332
## *****
```